# DATY

el agente de IA que te facilita buscar información para toma de decisiones del negocio

Prueba Técnica MercadoLibre
Julian Felipe Prieto Gutierrez

# Contexto

## Se requiere habilitar un agente de IA en dos fases:

**Fase 1: Construcción de la Refinería de Datos.** Implementamos un pipeline de procesamiento que transforma datos crudos en activos listos para el negocio, garantizando calidad, privacidad y velocidad en una base de datos optimizada.

**Fase 2: Darle voz a los datos.** Con los datos limpios, habilitamos al Agente de IA. El objetivo es que cualquier analista pueda preguntar en lenguaje sencillo (como si estuviera chateando) y obtener respuestas sin tener que escribir una sola línea de SQL.

# Decisiones de Diseño y Stack Tecnológico

**Modularidad y Escalabilidad:** Estructuramos el pipeline en módulos independientes para garantizar un **bajo acoplamiento**. Esto permite actualizar reglas de calidad o políticas de gobierno de manera quirúrgica, asegurando un sistema robusto, fácil de testear y listo para crecer con el volumen de datos.

| Herramienta | Rol en el Proyecto | ¿Por qué esta y no otra? |
|---|---|---|
| DuckDB | Motor Analítico (OLAP) | **Velocidad extrema:** Procesa datos en columnas (ideal para SQL) sin la latencia ni el costo de un servidor como PostgreSQL o BigQuery. |
| Groq + LangChain | Cerebro de **DATY** | **Latencia Cero:** Groq es 10x más rápido que GPT-4 tradicional. LangChain permite cambiar de modelo sin reescribir el código. |
| Pandas | Motor de Limpieza (ETL) | **Eficiencia:** Es el estándar para transformar datos. Usar Spark aquí sería *overengineering* (demasiada complejidad para este volumen) |

# Arquitectura

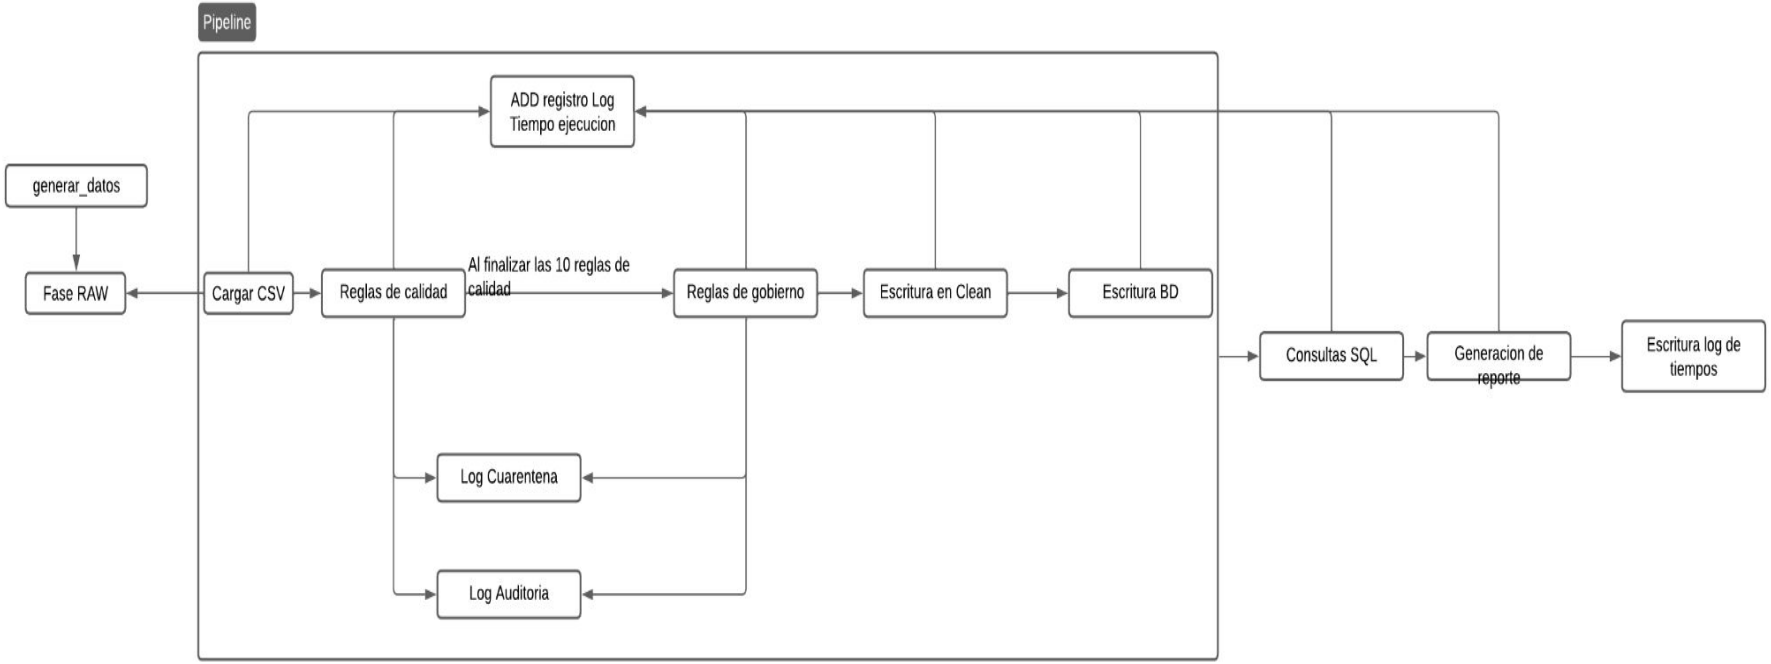

# Calidad de Datos

**Hallazgo clave:**

- Eventos: 4000 → 1509 (37.7% clean), 2491 purgados por retención (fecha > retencion_dias)

**Reglas principales aplicadas:**

- R1: Reglas de deduplicacion por PK
- R2: Nulos criticos (campos esenciales)
- R8: Hashing para campos de contacto del cliente
- R10: Masking para el telefono del cliente

**Antes/Después:**

- Eventos: 4000 → 1509
- Pedidos: 1200 → 1179

**Impacto negocio:**

- análisis confiable (menos ruido)
- cumple privacidad PII (GDPR)
- evita pérdidas por stock incorrecto

**Ciclo de Vida:** El hallazgo de que 4000 registros en la tabla de eventos, 2491 registros pasaron a estar purgados por la retención de días y reglas de calidad, demuestra que el flujo cumple con la consistencia del dato.

| | | | | |
|---|---|---|---|---|
| EVENTOS | 4000 | 2491 | 37.72% | 🚨 Crítico |

# Insights de Negocio

| Hallazgo | Impacto en el Negocio |
|---|---|
| Fricción en Mobile | La duración de sesión es significativamente menor que en Desktop, indicando una posible falla de UX en la App. |
| Concentración VIP | El Top 10 de clientes genera la mayor parte de los ingresos; es vital un plan de fidelización. |
| Alerta de Stock | **DATY** identificó productos críticos con **0 unidades** (como Deportiva Aliquam 892), permitiendo reabastecimiento inmediato. (PROD-0002) |

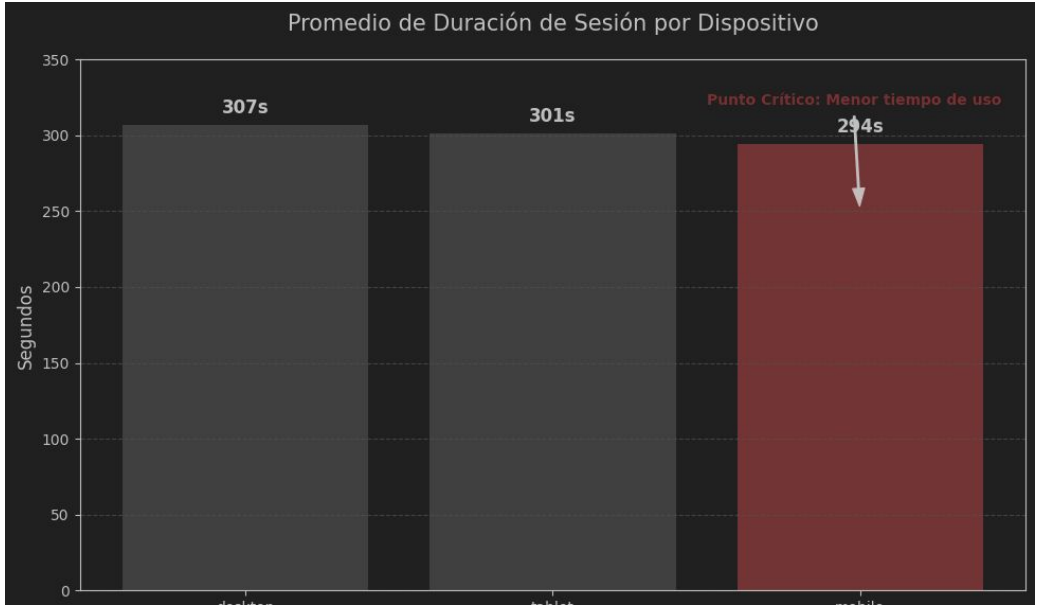

# DATY: Democratización del Dato con SQL Invisible

El agente es capaz de extraer la información de forma acertada mediante preguntas que ya las consultas SQL validaron en su momento

**Limitaciones:** Falta de memoria (El agente no recuerda conversaciones)

**Mejoras:** Implementación de memorias  (Para que el agente tenga un contexto de la conversación y pueda identificar el patrón para proponer)

Arquitectura de DATY: Inteligencia y Seguridad

**Cerebro (LLM)**: **Llama-3.3-70b** vía **Groq** para respuestas con latencia casi nula

**Orquestador**: **LangChain** para procesar lenguaje natural y transformar preguntas en SQL.

**Motor Analítico**: **DuckDB (OLAP)** in-memory para consultas sobre datos limpios a velocidad extrema.

```
🤔 Tu pregunta o salir: cual es el stock critico?

🔍 Analizando con lógica de negocio...

💡 RESPUESTA:
El stock critico se refiere a los productos que tienen un nivel de inventario muy bajo, en este caso, menos de 10 unidades disponibles. Al ejecutar la consulta SQL anterior, podemos identificar los productos que se encuent

Los resultados de la consulta muestran que hay 6 productos con stock critico:

1. Deportiva Aliquam 892 (PROD-0002) - 0 unidades disponibles
2. Smartphones Iste 978 (PROD-0005) - 0 unidades disponibles
3. Limpieza Alias 588 (PROD-0008) - 0 unidades disponibles
4. Limpieza Aut 469 (PROD-0016) - 6 unidades disponibles
5. Smartphones Quisquam 983 (PROD-0026) - 0 unidades disponibles
6. Laptops Enim 510 (PROD-0029) - 0 unidades disponibles
```

# Data Governance

**Linaje de Datos:**

- **Ingesta RAW:** Recepción de datos crudos.
- **Refinería:** Filtrado en capas **Clean** (aptos) y **Cuarentena** (para revisión) tras reglas de calidad.
- **Persistencia (DuckDB):** Aplicación de esquemas finales y escritura en tablas analíticas.
- **Trazabilidad:** Monitoreo mediante logs de auditoría y tiempos en todo el flujo.

**PII Protegido:** hash SHA-256 (email/nombre/apellido), masking teléfono (últimos 4 dígitos).

**Retención:** Dependiendo del criterio de retención de días se conserva o se elimina la información

**Agente seguro:** Válida output (bloquea PII), acceso restringido a datos sensibles.

# Conclusiones

**Baja eficiencia en el sur (Chile y Argentina):**

- **Hallazgo:** Tienen casi los mismos pedidos que el resto, pero generan mucho menos dinero ($276M y $302M).
- **El Problema:** Como los precios son iguales, los clientes allá compran menos unidades por pedido, y el envío nos sale más caro.
- **Propuesta:** Poner un mínimo de compra o promociones tipo "3x2" para que el carrito crezca y el envío valga la pena.

**Ventas dispersas (Sin producto estrella):**

- **Hallazgo:** Del producto 1 al 10 solo hay 31 unidades de diferencia; todo se vende casi igual.
- **El Problema:** No tenemos un líder claro. Manejar tantas categorías distintas (Deporte, Tabletas, Limpieza) hace la logística más lenta y costosa.
- **Propuesta:** Enfocar el marketing solo en las 2 categorías más fuertes para mover más volumen, negociar mejor con proveedores y simplificar la bodega.

**Fricción crítica en dispositivos Mobile:**

- **Hallazgo:** El celular es el dispositivo con menos tiempo de uso por sesión. Mientras el promedio esperado de uso diario es de 5 horas, nuestros cálculos muestran que el usuario solo dura **294 segundos (aprox. 5 minutos)** por evento.
- **El Problema:** Al ser el medio donde la gente más tiempo gasta normalmente, un tiempo tan bajo indica que algo está fallando. El usuario entra pero se sale rápido, perdiendo oportunidades de venta.
- **Propuesta:** Realizar una auditoría técnica urgente de la App y de la versión Web Mobile. Hay que revisar tiempos de carga o errores de diseño que estén afectando la experiencia y espantando al cliente.